

AI Engineer Programı — Hafta 2-3 Özeti

OpenAI Platform / Chat Completions · Structured Output · Streaming · Tool Calling Döngüsü

Proje 1: Sözleşme Risk Tarayıcısı — Next.js 15 + TypeScript + OpenAI (gpt-4.1)

Repo: github.com/baranboga/agreement-risk-analyzer · Tarih: 24 Ağustos 2026

BU HAFTANIN TEK CÜMLELİK ÖZETİ

Tool calling bir **kural** değil, modelin verdiği **olasılıksal bir karardır** — ve bir prompt değişikliğinin işe yarayıp yaramadığını, öncesini ölçmeden (baseline) asla bilemezsin.

1. Kavramlar — cilalanmış tanımlar

Chat Completions API stateless'tir

Modelin hafızası yoktur. Her istekte system prompt, tüm konuşma geçmişi, tool tarifleri ve kullanıcı metni **baştan** gönderilir. "Hatırlıyor" hissi, geçmişi her seferinde senin taşımandan doğar.

ÖLÇÜMLE KANITLANDI

350 token'lık kısa sözleşme + 2 tool turu → prompt **2.644** token (7,5 kat).

~8 kat uzun sözleşme + 0 tool turu → prompt **2.806** token.

Sonuç: Girdi maliyetini metnin uzunluğu değil, döngünün tur sayısı belirler.

Tool calling mekanizması

Modele araç vermek, ona fonksiyon vermek değildir. İsteğe fazladan bir **tarif listesi** eklemektir: ad, açıklama ve parametre şeması. Fonksiyonun kodu OpenAI'a hiç gitmez — model senin fonksiyonunu **görmez, çalıştırmaz, çalıştıramaz**. Gördüğü tek şey tariftir.

- Tarif gider.** İstekte metinle birlikte `tools: [...]` bloğu da yer alır. Bu blok her turda yeniden gönderilir (stateless).
- Model bir talep üretir.** Cevap metni yerine şu yapıda bir çıktı döndürür:
`{"name": "sureHesapla", "arguments": {"baslangicTarihi": "...", "gunSayisi": 30, "tur": "takvim"}}`. Bu bir *eylem* değil, bir *istektir*: "benim için şunu çalıştır."
- Fonksiyonu sen çalıştırırsın.** Kendi sunucunda, kendi kodunla. Bu adım internete çıkmaz. Modelin dünyaya dokunan hiçbir eli yoktur; elleri sensin.
- Sonucu konuşmaya eklersin.** Mesaj dizisi büyür: system → user (metin) → assistant (tool talebi) → tool (sonuç). Kullanıcı metni bu ikinci istekte **aynen tekrar** gönderilir.
- Model nihai cevabı üretir.** Artık tarihi *hesaplayarak* değil *okuyarak* biliyor.

Kararı model verir; kodunda `if (metinde "gün" geçiyorsa) ...` yoktur. Her turda kendi kendine "elimdeki tarif şu an işime yarar mı?" diye sorar. Bu **olasılıksal** bir karardır, mantıksal bir kural değil — bu yüzden tool'lu sistemler test edilmesi zor sistemlerdir.

Kararı etkileyen üç kaldıraç, üçü de senin elinde: **aracın adı**, **açıklaması** (en güçlüsü) ve **parametre açıklamaları**. Model kodu görmediği için aracın sınırlarını da bilmez: `sureHesapla` resmî tatilleri bilmiyorsa ve bu yalnızca kod yorumunda yazıyorsa, model o aracı kusursuz sanar ve sonucu kullanıcıya kesin bilgi olarak sunar. **Sınırı modele bildirmenin tek yolu açıklama metnidir.**

Agent'la ilişkisi. Özerklik bir açma/kapama düğmesi değil, bir eksendir. Altı karar noktası vardır: (1) bu aracı çağırayım mı, (2) hangi parametrelerle, (3) hangi aracı seçeyim, (4) plan kurayım mı, (5) sonucu görünce fikrimi değiştireyim mi, (6) işim bitti mi. Proje 1'de ilk ikisi modelde, diğer dördü sende. **Agent**,

çoğunluğun modelde olduğu sistemdir. Mekanizma aynıdır — eksik olan teknik bir uçurum değil, birkaç karardır: çok araç arasında seçim, zincirleme (bir tool'un çıktısı diğerinin girdisi), açık uçlu bitiş.

NOT AL

Tool döngüsü **minimum 2 tur** ister. `maxTurns = 1` ise tool sonucu modele asla ulaşamaz ve araç fiilen işlevsiz kalır. Limit bir kalite ayarı değil, **maliyet ve zaman tavanıdır**; model işini bitirdiğinde döngü kendiliğinden kırılır (ölçümlerde `maxTurns = 3` iken turlar 0, 1, 2 çıktı — hiç tavana dayanmadı).

Structured output ve zod

zod, TypeScript tiplerini çalışma zamanında denetlenebilir hale getiren bir doğrulama kütüphanesidir. Projede iki iş görür: şemayı JSON Schema'ya çevirip `strict: true` ile modele dayatmak, ve dönen cevabı doğrulamak.

KRİTİK AYRIM — MÜLAKATTA SORULUR

Yapısal hata (alan eksik, tip yanlış, enum dışı değer) → zod yakalar.

Dayanaksızlık / grounding (biçim kusursuz, değer uydurma) → zod göremez, çünkü kaynak metne bakmaz.

Şema kabı belirler, içeriği belirlemez.

Streaming ile structured output çelişkisi

Model JSON'u token token akıtır; yarım JSON parse edilemez. Üç yaklaşım: **(A)** tam cevabı bekle, **(B)** kısmi JSON'u onararak tamamlanmış maddeleri akıt, **(C)** satır başına bir nesne (JSONL) iste. C'nin bedeli, `strict` şema dayatmasından çıkmaktır.

2. Düzeltilen hatalar

HATA 1 — SEMANTİK SEARCH'Ü PM'E ANLATMA

"Veritabanında birbirine benzer cümleler aynı yöne bakar."

DÜZELTME

"Aynı yöne bakmak" gizli bir teknik terimdir (vektör yönü) ve veritabanında duran şey cümleler değil, sayısal temsilleridir. PM'in duyması gereken tek şey fayda:

"Kullanıcı 'kira kontratımı iptal edebilir miyim' yazdı, sistem içinde 'kira' kelimesi hiç geçmeyen tahliye dosyasını getirdi — çünkü arama artık kelimeleri değil, kastedileni eşleştiriyor."

HATA 2 — TEMPERATURE'I DOĞRULUKLA EŞİTLEMEK

"Hukuk chatbotunda kanunlar konusunda kesin/deterministik olsun; ama yorum da yapabilsin, o yüzden temperature yükselsin."

DÜZELTME — İKİ AYRI KARIŞIKLIK

(a) Determinizm ≠ doğruluk. Temperature 0, doğru cevabı değil *aynı* cevabı garanti eder. Model yanlış madde numarası uyduruyorsa, temp 0'da her seferinde aynı yanlışı uydurur. Doğruluk retrieval'dan, kaynak göstermekten ve "bilmiyorum" diyebilmekten gelir.

(b) Yorum ≠ yüksek temperature. Temperature yalnızca kelime seçimindeki rastgeleliği ayarlar, muhakeme derinliğini değil. Yüksek temperature modeli daha zeki değil, daha **değişken** yapar.

Üretim gerekçesi: aynı soruya iki farklı cevap = güven ve denetlenebilirlik problemi; ayrıca çıktı sabit olmazsa prompt değişiminin neyi bozduğu ölçülemez.

Tuzak bilgi: temperature 0 tam determinizm vermez. Sapma sampling'den değil altyapıdan gelir (batch'leme, kayan nokta aritmetiğinin sıra bağımlılığı, sonucu yönlendirmesi).

HATA 3 — JSONL FORMATINI "MALİYETLİ" SANMAK

"C seçeneği her seferinde yeni JSON gönderileceği için daha maliyetli olur."

DÜZELTME

JSONL'de ek istek yoktur; tek çağrı, tek akış, sadece çıktının biçimi değişir. Token sayısı neredeyse aynıdır. **Maliyet kaç kez istek attığından gelir, çıktığı nasıl formatladığından değil.** (Tool döngüsünde girdiyi tekrar ödeme kuralı doğrudur — ama burada çoklu istek yok.)

HATA 4 — PROMPT INJECTION'IN ETKİSİZ OLDUĞUNU SANMAK

"Görselde görüldüğü gibi uygulama şu an prompt injection'a karşı güvende, ama neden güvende olduğunu bilmiyorum."

DÜZELTME

Talimat uygulanmadı (tek bir DÜŞÜK kart yok) ama çıktı değişti: 5 bulgu → 3 bulgu, Gizlilik YÜKSEK → ORTA. Yine de **tek tarama kanıt değildir** — bulgu sayısı zaten kararsızdı; etkiyi ayırmak için enjeksiyonlu/enjeksiyonsuz metni beşer kez tarayıp dağılım karşılaştırmak gerekir.

Asıl teşhis: uygulamada **talimat ile veri arasında sınır yok**. Model için system prompt'taki "sen risk analistisin" cümlesi ile sözleşmenin içindeki "SİSTEM NOTU" cümlesi aynı türden şeydir: ikisi de token. Structured output kısmen korudu ama şema biçimi dayatır, içeriği değil.

"Bir savunmanın neden çalıştığını bilmiyorsan, o savunma senin değildir."

HATA 5 — YANLIŞ NEDENSELLİK (HAFTANIN EN ÖNEMLİ HATASI)

"Tool tarifine kısıt cümlesini ekledim, tool çağrılmadı → kısıt işe yaradı."

DÜZELTME

Kısıt kaldırıldığında davranış **geri dönmedi** — yani gözlem, müdahalenin kanıtı değildi.

Kök sebep: baseline ölçülmedi. Referans noktası olmadan sonraki ölçüm anlamsızdır — 0/3 sonucu, taban 3/3 ise büyük başarı, taban 0/3 ise hiçbir şey.

Ek katman: ilk deney kurulumunda taban zaten 0/5'ti (bkz. floor effect, §4). Kurulum düzeltilince gerçek sonuç çıktı: A 2/5 → B 0/5.

HATA 6 — ÇOK DEĞİŞKENLİ DENEY (İKİ KEZ TEKRARLANDI)

İlk kez: metni değiştirirken sıra, ifade, süre sayısı ve madde sayısı aynı anda değişti. İkinci kez: kısıt cümlesi hem tool tarifine hem system prompt'a birden eklendi.

DÜZELTME

Tek değişkenli deney kuralı: bir seferde tek şey değiştir, yoksa sonucun sebebinin söyleyemezsin. İki kısıt aynı anda eklendiğinde hangisinin etkili olduğu ölçülemez hale geldi — ve tool tarifinin tek başına gücü hakkında veri kaybedildi.

HATA 7 — ÖLÇÜM ALTYAPISININ KENDİSİ DOĞRULANMADI

Deney modu ayrı bir `deneySistemPromptu` ile yazılmıştı ve normal akıştaki "somut tarih yoksa bugünü başlangıç kabul et" satırı orada **yoktu**. Yani "A = kısıt yok" koşulu aslında "kısıt yok ve teşvik yok" idi.

DÜZELTME

Ölçüm koşullarının sabit olduğu **varsayılmaz, doğrulanır** — git diff ile. Kod yazdıran kişi, "dokunma" demenin dokunulmadığı anlamına gelmediğini bilmek zorundadır. Tek değişkenli deney kuralı yalnızca girdiye değil, **ölçüm altyapısına da** uygulanır. Bu hata bulunmasaydı yanlış bir nedensellik zinciri ("tool call, risk kartı üretimine bağlı alt karardır") sonuç olarak kayda geçecekti.

3. Ölçüm sonuçları

3.1 Maliyet — uzun sözleşme (10 maddelik, PDF)

Metrik	Mod B (streaming)	Mod A (bekle)
Prompt token	2.806	2.806
Completion token	1.164	1.239
Tool turu	0	0
Toplam maliyet	\$0,014924	\$0,015524
Bulgu sayısı	6	5

- Maliyetin **%62'si çıktıdan** geliyor — completion token girdinin 4 katı fiyatlı ve model madde başına gerekçe + öneri + alıntı yazıyor.
- Tahmin 0,5 sentti; gerçek ~1,5 sent → **3 kat sapma** (az tahmin edilmiş).
- Aynı metin, aynı model, iki tarama: **6 ve 5 bulgu**. Çıktı kararsız.

3.2 Gecikme (aynı uzun metin)

Metrik	Mod B	Mod A	Fark
TTFT	1,1 s	4,4 s	4×
İlk kart	2,3 s	14,8 s	6,4×
Toplam	7,5 s	14,8 s	2×

Mod B'de tek bir yarım/bozuk kart görünmedi. Başlangıçtaki "Mod B UI açısından kötü görünür" sezgisi ölçümle çürüdü; tercih Mod B lehine değiştirildi.

Gerekçenin doğru kurulumu: bu bir *tarama* aracı, sohbet değil. Kullanıcı birbirinden bağımsız okunabilen 5-10 bulgu bekliyor; sıralı akıtma ürünün doğasına uygun. Tek bütünsel cevap üreten bir üründe ("bu sözleşmeyi imzalamalı mıyım?") aynı tercih yanlış olurdu — yarım bir tavsiye yanlıştır.

Not: TTFT ölçümleri 1,1 s ve 4,4 s çıktı — aynı prompt, 4 kat fark. Latency için de tek ölçüm kanıt değildir; üretimde p95 ölçülür (Hafta 15-16).

3.3 Deney modu — tool çağırma oranı

Tur 1 — geçersiz kurulum (teşvik satırı deney promptundan düşmüştü):

Koşul	Tool oranı	Ort. bulgu
A — kısıt yok	0/5	3,8
B — kısıt tool tarifinde	0/5	4,0

Taban sıfır olduğu için **bastırıcı bir müdahale ölçülemez** (floor effect). Deney geçersiz.

Tur 2 — düzeltilmiş kurulum (üç koşulda ortak teşvik: "tarih yoksa bugünü varsay"):

Koşul	Metin	Tool oranı	Ort. bulgu	Yorum
A — kısıt yok	tarihsiz	2/5	3,8	Taban ölçülebilir
B — kısıt tool tarifinde	tarihsiz	0/5	4,0	Kısıt bastırdı
B — kısıt tool tarifinde	tarihli + süreli	0/6	3,2	Yanlış-negatif

ÜÇ SONUÇ

- 1. Tool tarifi, system prompt'u bastırabiliyor.** System'deki "tarih yoksa bugünü varsay" teşviki, tool açıklamasına yazılan tek bir kısıt cümlesiyle tamamen etkisizleştirdi (2/5 → 0/5). Sezgiye aykırı bulgu: çoğu kişi system prompt'u daha güçlü sanır — ölçüm **araca en yakın talimatın** kazandığını söylüyor.
- 2. Kısıt ayırım yapmıyor (yanlış-negatif).** Metinde tarih de süre de açıkça varken bile 0/6. Kısıt yalnızca dayanaksız çağrılar değil, **meşru çağrılar da öldürüyor**. Bu haliyle üretime alınamaz. Muhtemel sebep: yasak cümlesinin mutlaklığı ("...ise ÇAĞIRMA") izin kısmını gölgeliyor. Test: kısıt pozitif kur ("tarih varsa mutlaka çağır, yoksa çağırma") ve oranı yeniden ölç.
- 3. Teşvik varken bile 2/5.** System prompt açıkça "bugünü varsay" dediği halde model beş taramanın üçünde çağırmadı. *Talimat bir eğilimdir, garanti değil — kritik kararlar kod tarafında da savunulmalıdır.*

Yan gözlem — regression: ortalama bulgu sayısı deney boyunca 3,8 → 4,0 → 3,6 → 3,2 arasında oynadı ve hiçbirinde bu metrik hedeflenmedi. Tarif değişti, oynadı; metin değişti, oynadı. **Prompt'ta yapılan hiçbir değişiklik izole değildir.** Regression testing'in (Hafta 9-10) varlık sebebi budur.

Prompt token kanıtı — stateless kuralı: A koşulunda tool çağrılmayan taramalarda PT **818**, çağrılan iki taramada **1.699**. Aynı metin, aynı model; tek fark bir ek tur ve girdi maliyeti iki katına çıktı.

3.4 Modelin üç ayrı tool davranışı

Davranış	Gözlem	Kullanıcıya etkisi
Aracı çağırdı, başlangıç tarihini uydurdu	başlangıçTarihi: "2026-08-22" (bugün) — metinde imza tarihi yok	Yanlış ama kesin görünen tarih — rozet olarak sunuluyor
Aracı hiç çağırmadı, sustu	Madde 1 ("15 iş günü") için hiç çağrı yok	Sessiz eksiklik — kullanıcı vadeyi hiç görmedi, uyarı da yok
Aracı çağırmadı, kendisi hesapladı	Tool turu 0, ama ekranda "2027-08-24 / 2027-08-09" tarihleri var	Denetlenemeyen tarih — log'a bakan "hesap yok" sanır

Üçüncüsü en tehlikelidir: araç sessizce devre dışı kalır, ürün çalışıyor görünür, sonuçlar makul görünür.

3.5 Hipotez zinciri — çürütmeler

#	Hipotez	Test	Sonuç
a	"İmza tarihi" somut geldiği için model varsayım yapıyor	Aynı kalıp farklı metinde	Çürüdü
b	tur: "is" parametresi caydırdı	takvim ile denendi	Çürüdü
c	Konum etkisi (son madde çağırıyor)	Aynı metnin 2. taraması Madde 1'i de çağırdı	Çürüdü
d	Karar olasılıksal ve eşige yakın	Aynı girdi, farklı sonuçlar	Kısmen ayakta
e	Girdi eksik olduğu için çağırıyor	Metne 01.09.2026 eklendi	Çürüdü (yine 0 çağrı)
f	Tool call, risk kartı üretimine bağlı alt karardır	Kod incelemesi gizli değişkeni ortaya çıkardı	Çürüdü / gereksiz
g	Deney promptunda teşvik satırı eksikti	Satır geri konuldu → A koşulu 0/5'ten 2/5'e çıktı	Doğrulandı

Hipotez (f), elde eksik bir deney kurulumu varken kurulmuş karmaşık bir nedensellik zinciriydi. Basit açıklama (bir prompt satırı düşmüştü) ortaya çıkınca zincir çöktü. **Karmaşık bir açıklama kurmadan önce, ölçüm kurulumunun kendisini doğrula.** Yedi hipotezden beşi ölçümle çürütüldü — süreç olarak doğru olan budur: tahmin → ölç → çürüt → yeniden kur.

4. Deney metodolojisi — bu haftaki ölçümler vs. sektör standardı

Bu haftaki ölçümler **öğrenme amaçlıydı ve istatistiksel olarak yetersizdir**. Gerçek bir eval kurulumunda neyin farklı olacağını bilmek, mülakatta ölçümü savunabilmenin ön koşuludur.

Boyut	Bu hafta yapılan	Sektörde olması gereken
Örnek sayısı	1 sözleşme, 5-6 tekrar	30-50 farklı sözleşmelik golden dataset , her biri en az 3 tekrar
Çeşitlilik	Tek şablon, yapay metin	Gerçek, dağınık belgeler: farklı uzunluk, format, tarih ifadesi, dil
Beklenen çıktı	Tanımsız — "makul mü?" gözle	Her örnek için etiketlenmiş doğru cevap (araç çağrılmalı mıydı, hangi parametrelerle)
Metrik	Ham oran (2/5)	Precision / recall : doğru-pozitif, yanlış-pozitif, yanlış-negatif ayrı ayrı
Belirsizlik	Yok — tek sayı	Güven aralığı; 5 örnekte 2/5 ile 4/5 arasındaki fark gürültü olabilir
Çalıştırma	Elle, UI'dan	CI'da otomatik; her prompt değişikliğinde koşar (regression)
İzlenebilirlik	Ekran görüntüsü	Tracing (Langfuse / LangSmith): her çağrı, parametre ve token kaydedilir
Karşılaştırma	Tek model (gpt-4.1)	En az 2 model + fiyat/kalite eğrisi

Deney tasarımının altı kuralı

- Baseline önce ölçülür.** Müdahalenin etkisi ancak öncesine göre tanımlıdır.
- Taban ölçülebilir aralıkta olmalı (floor / ceiling effect).** Bastırıcı bir müdahale test edilecekse taban sıfır olamaz; artırıcı bir müdahale test edilecekse taban tavanda olamaz.
- Tek değişken.** Bir seferde tek şey değişir — girdi, prompt, model, mod: yalnızca biri.
- Ölçüm altyapısı da bir değişkendir.** "Sabit kaldı" varsayılmaz, `git diff` ile doğrulanır.
- Tek gözlem kanıt değildir.** LLM çıktısı aynı girdide bile değişir; oran ölçülür, örnek değil.
- Yanlış-negatif de ölçülür.** Bir kısıtın hedefi bastırmak olsa bile, meşru durumları bastırıp bastırmadığı ayrıca test edilir. Tek yönlü ölçüm yanıltır.

MÜLAKATTA SÖYLENECEK CÜMLE

"Ölçümlerim küçük örneklemler ve öğrenme amaçlıydı; üretim kararı için 30-50 örneklilik etiketli bir set üzerinde precision/recall ölçer, CI'da regression testine bağladım." — Ölçümün sınırını bilmek, ölçüm yapmaktan daha ayırt edicidir.

5. Mülakat soruları ve cevap iskeletleri

S1 Tool calling'i nasıl uyguladın?

İsteğe metinle birlikte araç tariflerini gönderiyorum. Model cevap yerine, hangi aracı hangi parametrelerle çağırmak istediğini söyleyen bir talep dönebiliyor. O fonksiyonu kendi sunucumda ben çalıştırıyorum; sonucu konuşmaya yeni bir mesaj olarak ekleyip modele ikinci kez gidiyorum. Döngüyü ben yönetiyorum, tur limitini ben koyuyorum.

S2 Bu bir agent mı?

Hayır — agent'ın çekirdeği. Özerklik bir eksen: "çağırayım mı" ve "hangi parametrelerle" kararları modelde; "hangi aracı seçeyim", "plan kurayım mı", "sonucu görünce fikrimi değiştireyim mi", "işim bitti mi" kararları bende. Agent, çoğunluğun modelde olduğu sistemdir. *Mülakatta "agent yazdım" deme; ne yaptığını anlat.*

S3 Modelin sessizce aracı atladığını üretimde nasıl fark edersin?

Manuel kontrol ölçeklenmez. Otomatik sinyal: çıktıda hesaplanmış tarih var **ama** `toolTurns === 0` ise bayrak kaldır. Loglanacaklar: tarama başına tool çağrı sayısı, tool'suz üretilen tarih sayısı, ve zaman içinde **tool kullanım oranı**. Alarm tekil olayda değil **oranın kaymasında**: "geçen hafta %70, bu hafta %20" cümlesi prompt'un ya da modelin değiştiğini söyler.

S4 Maliyeti yarıya indir deseler? (bu üründe paranın %62'si çıktıda)

1. Alıntıyı kısalt — sözleşme cümlesi kartta birebir kopyalanıyor, yani girdide bir kez ödenen metin çıktıda ikinci kez ödeniyor. Karakter aralığı döndürüp UI'da kes. *Bedeli: frontend işi.*
 2. Gerekçe/öneriyi "en fazla 2 cümle" ile sınırla. *Bedeli: hukuki nüans kaybı.*
 3. Sadece orta+yüksek riskleri döndür. *Bedeli: kullanıcı "tarandı mı" şüphesi.*
 4. Prompt caching — system prompt ve tool tarifleri sabit, her turda tekrar gidiyor. *Bedeli ~yok.*
- Yanlış hedef:* tool call'ı sınırlamak — bu üründe turlar zaten 0-2 arası, kesecek yağ yok.

S5 Streaming mi, tam cevap mı?

Ölçüm: ilk kart 2,3 s'ye karşı 14,8 s. Bağımsız okunabilen bulgular üreten bir tarama aracında sıralı akıtma doğru; tek bütünsel tavsiye üreten bir üründe yanlış olurdu, çünkü yarım tavsiye yanıltır.

S6 Prompt değişikliğinin işe yaradığını nasıl bilirsin?

Bilemezsin — baseline ölçmediysen. Ben ölçmedim ve yanıldım: kısıt cümlesini ekledim, tool çağrılmadı, "işe yaradı" sandım. Kaldırdığımda davranış geri dönmedi. Deney kurunca ilk kurulumun da geçersiz olduğu çıktı (taban 0/5 — floor effect). Düzeltilmiş kurulumda gerçek sonuç: A 2/5 → B 0/5, yani tool tarifi system prompt'unu bastırıyor. Ama aynı kısıt, tarih gerçekten varken de çağrıyı engelledi (0/6) — yanlış-negatif, üretime alınamaz. Ayrıca kısıt hedeflemediği bir metriği (ortalama bulgu sayısı) değiştirdi; prompt değişiklikleri regression testine tabi tutulmalı.

S7 Şema doğrulaması modelin uydurmasını engeller mi?

Hayır. zod **biçim** denetler, **doğruluk** denetlemez. "2026-08-22" geçerli bir ISO tarihtir ve şemayı geçer; o tarihin kaynak metinde geçip geçmediğini şema bilemez. Yakalamak için ayrı bir grounding katmanı gerekir: değeri kaynak metinde ara, yoksa çağrıyı reddedip modele "metinde tarih yok" diye dön.

S8 Prompt injection'a karşı durumun ne?

Açık: **talimat ile veri arasında sınır yok**. Kullanıcının yapıştırdığı metin düz kullanıcı mesajı olarak gidiyor; model için system prompt'taki talimat ile metnin içindeki "SİSTEM NOTU" aynı türden token. Structured output kısmen korur (model şemadan çıkamaz) ama kaç kart üretileceğine ve risk seviyesine yine model karar verir.

S9 System prompt mu, tool açıklaması mı daha güçlü?

Ölçüm: system prompt'ta "tarih yoksa bugünü varsay" teşviki varken taban 2/5. Tool açıklamasına tek bir kısıt cümlesi ekleyince 0/5. **Araca en yakın talimat kazandı.** Ama aynı kısıt meşru çağrılar da engelledi (0/6), yani güçlü olması doğru olması anlamına gelmiyor. Bir talimatın gücü kadar **seçiciliği** de ölçülmeli.

S10 Ölçümlerinin sınırı ne?

Küçük örneklem (tek sözleşme, 5-6 tekrar), etiketlenmiş beklenen çıktı yok, güven aralığı hesaplanmadı, tek model. Üretim kararı için 30-50 örneklik golden dataset üzerinde precision/recall ölçer, CI'da regression'a bağlar, tracing ile her çağrıyı kaydederdim. *Ölçümün sınırını bilmek, ölçüm yapmaktan daha ayırt edicidir.*

6. Hafta 4'e devreden konular

- **Prompt injection savunması** — teşhis yapıldı, savunma bilinçli olarak eklenmedi. Enjeksiyonlu/enjeksiyonsuz metni beşer kez tarayıp etkiyi istatistiksel olarak ayırmak ilk iş.
- **Constraining inputs/outputs** — grounding katmanı: model çıktısındaki değerlerin kaynak metinde bulunup bulunmadığının kontrolü.
- **Ollama ile yerel model** — aynı sözleşmeyi açık kaynak bir modele taratıp tool davranışını karşılaştırmak, OpenAI bağımlılığını kırar.

7. Açık kalan iş

- **Pozitif kurulmuş kısıt testi** — "tarih varsa mutlaka çağır, yoksa çağırma". Yanlış-negatifin yasak cümlesinin mutlaklığından mı geldiğini gösterir. En değerli açık deney.
- **C koşulu** (tool + system) — B zaten 0/5 olduğu için bilgi değeri düşük, bilinçli atlandı.
- **Kod tarafı savunma** — modelin ürettiği `baslangicTarihi` kaynak metinde aranmadan fonksiyona giriyor. Grounding kontrolü eklenmeli (Hafta 4).
- **E bölümü** (context limiti, iptal, bozuk API key) — mühendislik hijyeni, bilinçli olarak düşürüldü.
- **F bölümü** (kaçırılan riskler / yanlış alarmlar) — hukuki değerlendirme gerektirdiği için ertelendi; golden dataset kurulurken yapılacak.